Recuperación Multi-Instancia Visual-Textual en Videos Egocéntricos: Desarrollo de Modelos de Alineación Semántica para el EPIC-KITCHENS-100 Challenge

María Castro Iregui Santiago Martínez Novoa
Nicolás Rozo Fajardo Juan Sebastián Urrea López

1 Contexto y problema

1.1 Situación actual

El crecimiento del contenido audiovisual ha impulsado el desarrollo de métodos capaces de analizar, indexar y recuperar información visual de forma automatizada. En este contexto, la recuperación multimodal entre video y texto se ha consolidado como un área relevante en la intersección entre las disciplina de visión por computador y procesamiento del lenguaje natural.

Un escenario desafiante para estas tareas corresponde a los videos egocéntricos, los cuales capturan actividades desde una perspectiva de primera persona usando cámaras montadas en el cuerpo o la cabeza. Este tipo de videos registra interacciones naturales entre manos, objetos y entorno, lo que introduce alta variabilidad visual y temporal. En consecuencia, los modelos deben ser capaces de interpretar acciones y relaciones contextuales para establecer correspondencias precisas entre el contenido visual y su descripción textual.

Uno de los recursos más relevantes para este problema es el dataset *EPIC-KITCHENS-100*, que contiene más de 100 horas de video egocéntrico en entornos domésticos reales y alrededor de 90 000 segmentos anotados. Sobre este dataset se desarrolla el *EPIC-KITCHENS-100 Multi-Instance Retrieval Challenge*, cuyo objetivo es alinear clips de video y descripciones textuales mediante matrices de relevancia con etiquetas suaves (*soft labels*), permitiendo modelar distintos grados de similitud semántica entre pares video–texto.

1.2 Problema y relevancia en el contexto

A pesar de los avances recientes en modelos multimodales, la alineación semántica entre video y lenguaje natural continúa siendo un desafío, especialmente en escenarios egocéntricos. La dinámica de estos videos, caracterizada por cambios constantes de perspectiva, oclusiones y múltiples interacciones entre objetos, dificulta la extracción de representaciones visuales robustas.

Adicionalmente, en tareas de recuperación multimodal un mismo video puede estar relacionado con múltiples descripciones en distintos niveles de similitud. Esto exige modelos capaces de estimar relaciones semánticas continuas entre video y texto, superando enfoques basados únicamente en correspondencias binarias. Así, resulta necesario desarrollar métodos que integren representaciones visuales y textuales en un espacio semántico compartido, permitiendo modelar de manera más precisa las relaciones entre acciones observadas y descripciones en lenguaje natural.

1.3 Impacto esperado

Este proyecto contribuirá al estudio de métodos de aprendizaje profundo para la alineación semántica entre video y lenguaje natural en escenarios egocéntricos. Los resultados permitirán explorar estrategias para generar representaciones multimodales capaces de modelar distintos grados de similitud entre ambas modalidades. Avances en estos métodos pueden facilitar el desarrollo de sistemas de búsqueda y organización automática de grandes repositorios de video, así como aplicaciones en asistentes inteligentes basados en visión egocéntrica y análisis automatizado de actividades humanas.

2 Objetivo general

Desarrollar y evaluar un modelo de aprendizaje profundo para la recuperación multimodal entre video y texto utilizando el dataset *EPIC-KITCHENS-100*, capaz de identificar representaciones semánticas compartidas que permitan alinear segmentos de video egocéntrico y descripciones textuales para así generar rankings de relevancia en tareas de recuperación video–texto y texto–video.

3 Objetivos específicos

1. Analizar la estructura del dataset *EPIC-KITCHENS-100* y las matrices de relevancia utilizadas en el reto de recuperación multimodal, identificando la organización de los segmentos de video, las descripciones textuales y sus relaciones semánticas.

2. Diseñar una arquitectura de aprendizaje profundo que integre representaciones visuales temporales y representaciones semánticas del lenguaje para proyectar ambas modalidades en un espacio de características compartido.

3. Implementar y entrenar el modelo propuesto para estimar la similitud semántica entre pares video–texto y generar rankings de recuperación para ambas direcciones de búsqueda.
4. Evaluar el desempeño del modelo mediante métricas de ranking como *Normalized Discounted Cumulative Gain* (nDCG) y *Mean Average Precision* (mAP), comparando los resultados con enfoques base reportados en la literatura.

4 Estado del arte

La recuperación multimodal entre video y texto ha experimentado avances acelerados en los últimos años, impulsada por la convergencia de tres líneas de investigación: el aprendizaje contrastivo, los modelos fundacionales de visión y lenguaje, y la comprensión de video en primera persona. Esta sección revisa los trabajos más relevantes organizados en torno a tres ejes temáticos: (i) adaptación de modelos visión-lenguaje para recuperación de video, (ii) preentrenamiento multimodal en el dominio egocéntrico, y (iii) recuperación multi-instancia con relevancia graduada.

Adaptación de modelos visión-lenguaje para la recuperación de video

Los modelos de preentrenamiento contrastivo imagen-texto aprenden espacios de representación compartidos a partir de grandes colecciones de pares imagen-texto, y sentaron las bases para la recuperación multimodal con video. Luo et al. propusieron CLIP4Clip, un estudio empírico que adapta esta clase de modelos a la recuperación de clips de video mediante tres estrategias de agregación temporal: promediado de representaciones de fotogramas, transformadores secuenciales y acoplamiento estrecho entre codificadores [1]. Sus experimentos en los conjuntos MSR-VTT, MSVD y ActivityNet Captions mostraron que la calidad de las representaciones preentrenadas supera en importancia la elección de la estrategia de agregación temporal, lo que refuerza el papel central del espacio de representación compartido. Ma et al. extendieron este paradigma con X-CLIP, que introduce un aprendizaje contrastivo de múltiple granularidad capaz de alinear simultáneamente pares video-oración a nivel global y pares fotograma-palabra a nivel local, mediante un transformador de comunicación entre fotogramas [2]. Esta captura de correspondencias de grano fino representa una mejora notable frente a los métodos de alineación de nivel único. En una dirección complementaria, Rasheed et al. demostraron con ViFi-CLIP que el fine-tuning de extremo a extremo de modelos visión-lenguaje para video, con modificaciones arquitectónicas mínimas, alcanza resultados competitivos en generalización zero-shot [3], lo que evidencia que los espacios de embedding compartidos poseen una alta capacidad de transferencia hacia nuevos dominios.

Preentrenamiento multimodal en el dominio egocéntrico

El video en primera persona presenta retos particulares: movimiento dinámico de cámara, alta variabilidad intraclase en acciones cotidianas y una distribución de datos muy distinta a la del video en tercera persona. El corpus que hizo posible el preentrenamiento a escala en este dominio es Ego4D, recopilado por Grauman et al. en una colaboración de trece universidades y Meta AI [4]. Con más de 3 600 horas de video en primera persona grabadas por 931 participantes en nueve países, Ego4D estableció la infraestructura de datos sobre la que se construyen los modelos egocéntricos más recientes. Damen et al. introdujeron EPIC-KITCHENS-100, el conjunto de datos de referencia para actividades culinarias egocéntricas, que establece además la tarea de recuperación multi-instancia (MIR) basada en matrices de relevancia con etiquetas suaves [5]. Esta formulación reconoce que múltiples segmentos de video pueden ser relevantes para una misma consulta textual con distintos grados de similitud semántica, lo que exige métricas de evaluación sensibles al orden (como nDCG y mAP) en lugar del tradicional R@K.

Para capitalizar la disponibilidad del corpus Ego4D, Lin et al. presentaron EgoVLP, el primer modelo de preentrenamiento video-lenguaje diseñado específicamente para el dominio egocéntrico [6]. EgoVLP introduce EgoNCE, una variante de InfoNCE que pondera pares positivos adicionales mediante coincidencia de verbos y sustantivos, y obtiene mejoras sustanciales sobre métodos de dominio general en EK-100. Sin embargo, el manejo de instancias múltiples en EgoNCE se basa en solapamiento léxico y no aprovecha directamente las matrices de relevancia graduada oficiales del reto. Zhao et al. avanzaron en esta dirección con LAVILA, que emplea un modelo de lenguaje ajustado sobre Ego4D para generar narraciones diversas de los clips de entrenamiento, enriqueciendo la supervisión semántica disponible [7]. LAVILA alcanzó el estado del arte en EK-100 MIR en el momento de su publicación y se consolidó como codificador de video de referencia para trabajos posteriores. Pramanick et al. propusieron EgoVLPv2, que integra la fusión entre modalidades directamente en el tronco de la red mediante capas de atención cruzada intercaladas con las de auto-atención [8], obteniendo representaciones conjuntas más ricas al capturar dependencias temporales y semánticas de manera integrada.

Recuperación multi-instancia, relevancia graduada y modelos fundacionales

La línea de base oficial del reto EK-100 MIR combina dos modelos provistos por los organizadores. El primero es JPoSE, propuesto por Wray et al., que aprende espacios de embedding separados para verbos, sustantivos y acciones completas, y los combina para recuperación de grano fino [9]. El segundo es MI-MM, una adaptación de MIL-NCE [10] con pérdida multi-instancia MaxMargin y características S3D, que sirve como punto de comparación explícito del challenge. Ambos modelos operan con objetivos de relevancia binaria y no aprovechan las matrices de etiquetas suaves.

El escalado hacia modelos fundacionales de video más amplios ha empujado los límites de la comprensión multimodal. Wang et al. presentaron InternVideo2, que combina preentrenamiento con enmascaramiento de video, alineación visual-textual contrastiva y fine-tuning basado en instrucciones, alcanzando resultados de vanguardia en más de sesenta conjuntos de evaluación [11]. En el contexto específico del reto EK-100 MIR, Wang, Wang y Chau propusieron una pérdida de similitud múltiple simétrica que incorpora las matrices de relevancia con etiquetas suaves directamente en el cómputo del costo, aplicándose de forma simétrica sobre representaciones visuales y textuales [12]. Este enfoque, construido sobre LAVILA como codificador base, representa uno de los intentos más explícitos de optimizar directamente las métricas nDCG y mAP de la competición.

Paralelamente, la comunidad de recuperación visual ha desarrollado funciones de pérdida que optimizan directamente métricas de ranking. Engilberge et al. propusieron SoDeep, una red auxiliar que aprende a aproximar la operación de ordenamiento para hacer diferenciable el cómputo de mAP y Recall, aplicándola con éxito a recuperación cruzada texto-imagen [13]. Brown et al. introdujeron Smooth-AP, una aproximación sigmoidal del Average Precision que permite su optimización directa a gran escala en recuperación de imágenes [14]. A pesar de estos avances, esta familia de métodos no ha sido explorada sistemáticamente en el contexto de recuperación video-texto con relevancia graduada, lo que representa una oportunidad directa para el presente trabajo.

Brechas identificadas y enfoque del proyecto

A pesar de los avances descritos, persisten limitaciones importantes. La mayoría de los métodos de recuperación video-texto fueron concebidos para videos en tercera persona con anotaciones de relevancia binaria, sin considerar la estructura multi-instancia del escenario egocéntrico. Los modelos especializados en primera persona, como EgoVLP y LAVILA, emplean funciones de pérdida que solo aprovechan parcialmente las matrices de relevancia graduada: EgoNCE utiliza solapamiento léxico como sustituto de la similitud semántica real, mientras que LAVILA aplica aprendizaje contrastivo estándar sin distinción de grados de relevancia. Los enfoques que sí incorporan etiquetas suaves, como el de Wang et al. [12], lo hacen como etapa de fine-tuning sobre representaciones preentrenadas con objetivos binarios. El presente proyecto busca cerrar esta brecha mediante el desarrollo de un modelo de recuperación multimodal que aprenda representaciones semánticas compartidas para segmentos de video egocéntrico y descripciones textuales, integrando explícitamente las matrices de relevancia con etiquetas suaves desde el propio proceso de entrenamiento, con el objetivo de maximizar directamente las métricas nDCG y mAP del reto EPIC-KITCHENS-100 MIR.

5 Methodology and propososed focus

5.1 Technical focus

This project will begin with a thorough analysis of the dataset, presented in the following section. During this stage, we will identity it's structure, composition and possible pre-processing filters that can be applied to enhance the training data.

Then, we will begin with the design of an ML/DL architecture based on the foundational models established in EgoVLP, LAVILA and JPoSE. Starting off from foundational models proves useful in fine-tuning and will enable an exploration of the impact of processing in multimodal retrieval.

To implement and experiment this architecture, we will use modern and robust MLOps pipeline that pulls weights from AVION ViT-L/14, SMS-Loss (2024) and CR-CLIP (2025). Experiment management will be done with HYDRA and composable YAML files.

This pipeline will enable experimentation and clear analysis of metrics (nDCG and mAP) in order to select and iterate on the best results.

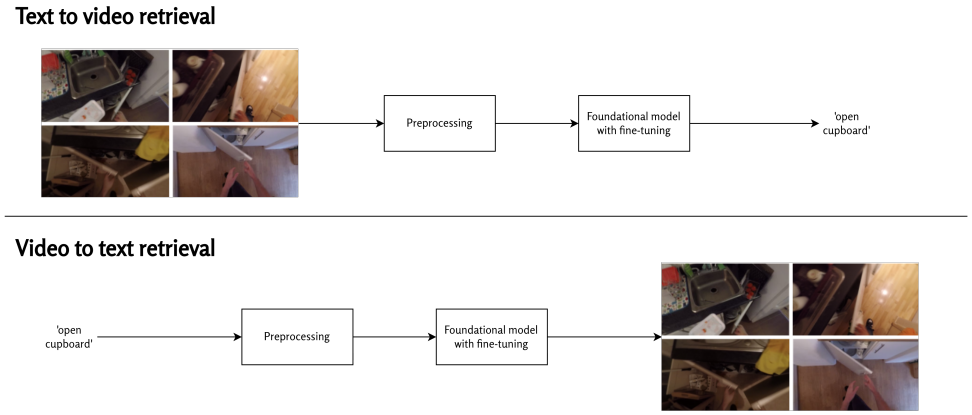

Figure 1: Diagram of solution with expected inputs an outputs. Images adapted from [15]

5.2 Libraries and Tools

The following libraries will be used:

```
PyTorch, torchvision, torchaudio (CUDA 12.1)
transformers, timm, einops
hydra-core, omegaconf, pydantic
wandb, tensorboard
matplotlib, seaborn, plotly
```

6 Exploración y descripción de los datos.

6.1 Características de los datos

Descripción de las fuentes de datos disponibles y su perfilamiento y características. En caso de que sea necesario recolectar más imágenes indicar las fuentes utilizadas.

6.2 Desarrollo de exploración

Debe anexar un notebook de la exploración.

- promedio de pixeles

- distribución de cada imagen, tamaño

- resolución

- gráficas

- ejemplo de imagen

- datos sobre videos (duración, resolucion, fps)

– promedio longitud de video

References

[1] H. Luo, L. Ji, M. Zhong, Y. Chen, W. Lei, N. Duan, and T. Li, "CLIP4Clip: An empirical study of CLIP for end to end video clip retrieval and captioning," *Neurocomputing*, vol. 508, pp. 227–235, 2022.

[2] Y. Ma, G. Xu, X. Sun, M. Yan, J. Zhang, and R. Ji, "X-CLIP: End-to-end multi-grained contrastive learning for video-text retrieval," in *Proceedings of the 30th ACM International Conference on Multimedia*. ACM, 2022, pp. 638–647.

[3] H. Rasheed, M. U. Khattak, M. Maaz, S. Khan, and F. S. Khan, "Fine-tuned CLIP models are efficient video learners," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023, pp. 10 630–10 640.

[4] K. Grauman, A. Westbury *et al.*, "Ego4D: Around the world in 3,000 hours of egocentric video," in *CVPR*, 2022, pp. 18 995–19 012.

[5] D. Damen, H. Doughty, G. M. Farinella, A. Furnari, J. Ma, E. Kazakos, D. Moltisanti, J. Munro, T. Perrett, W. Price, and M. Wray, "Rescaling egocentric vision: Collection, pipeline and challenges for EPIC-KITCHENS-100," *International Journal of Computer Vision*, vol. 130, no. 1, pp. 33–55, 2022.

[6] K. Q. Lin, A. J. Wang, M. Soldan, M. Wray, R. Yan, E. Z. Xu, D. Gao, R.-J. Tu, Z. Zhao, E. Lawrence *et al.*, "EgoVLP: Egocentric video-language pre-training," in *Advances in Neural Information Processing Systems*, vol. 35, 2022, pp. 6575–6586.

[7] Y. Zhao, I. Misra, P. Krähenbühl, and R. Girdhar, "Learning video representations from large language models," in *Proceedings of the IEEE/CVF Conference on Computer Vision and Pattern Recognition*, 2023, pp. 6586–6597.

[8] S. Pramanick, Y. Song, S. Nag, K. Q. Lin, H. Shah, P. Torr, R. Nevatia, and D. Gao, "EgoVLPv2: Egocentric video-language pre-training with fusion in the backbone," in *Proceedings of the IEEE/CVF International Conference on Computer Vision*, 2023, pp. 5285–5297.

[9] M. Wray, D. Larlus, G. Csurka, and D. Damen, "Fine-grained action retrieval through multiple parts-of-speech embeddings," in *ICCV*, 2019, pp. 450–459.

[10] A. Miech, J.-B. Alayrac, L. Smaira, I. Laptev, J. Sivic, and A. Zisserman, "End-to-end learning of visual representations from uncurated instructional videos," in *CVPR*, 2020, pp. 9879–9889.

[11] Y. Wang, K. Li, X. Li, J. Yu, Y. He, G. Chen, B. Pei, R. Zheng, J. Xu, Z. Wang *et al.*, "InternVideo2: Scaling foundation models for multimodal video understanding," *arXiv preprint arXiv:2403.15377*, 2024.

[12] X. Wang, Y. Wang, and L.-P. Chau, "Symmetric multi-similarity loss for epic-kitchens-100 multi-instance retrieval challenge 2024," 2024. [Online]. Available: https://arxiv.org/abs/2406.12256

[13] M. Engilberge, L. Chevallier, P. Pérez, and M. Cord, "SoDeep: A sorting deep net to learn ranking loss surrogates," in *CVPR*, 2019, pp. 10 784–10 793.

[14] A. Brown, W. Xie, V. Kalogeiton, and A. Zisserman, "Smooth-AP: Smoothing the path towards large-scale image retrieval," in *ECCV*, 2020, pp. 677–694.

[15] D. Damen, H. Doughty, G. M. Farinella, A. Furnari, E. Kazakos, J. Ma, D. Moltisanti, J. Munro, T. Perrett, W. Price, and M. Wray, "Rescaling egocentric vision," *CoRR*, vol. abs/2006.13256, 2020. [Online]. Available: https://arxiv.org/abs/2006.13256